12-Reinforcement Learning（強化學習）

1. 甚麼是 RL？

應用場景：

- 給機器一個輸入，但我們不知道最佳輸出為何
- 收集有標註的資料有難度

例如叫機器學習下圍棋，最好的下一步可能人類根本不知道。在不知道正確答案是什麼的情況下，就可以使用 RL

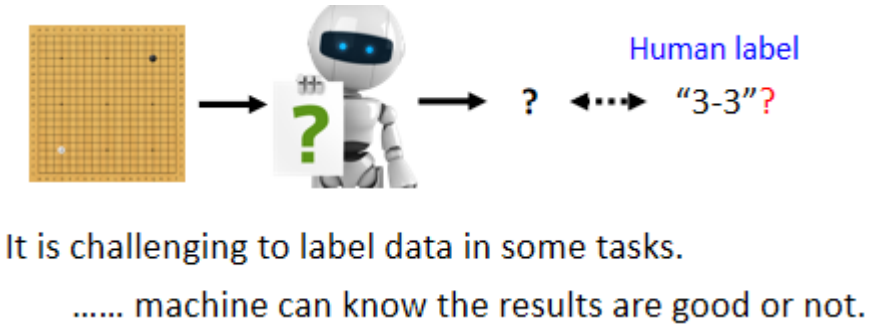

1.1 Actor

Reinforcement Learning 中有 **Actor** 及 **Environment，Actor 跟 Environment 會進行互動。**
actor 就是 RL 中要找的 **function**，輸入為 observation，輸出為 action，function 的目標是最大化從 environment 獲得的 reward 總和

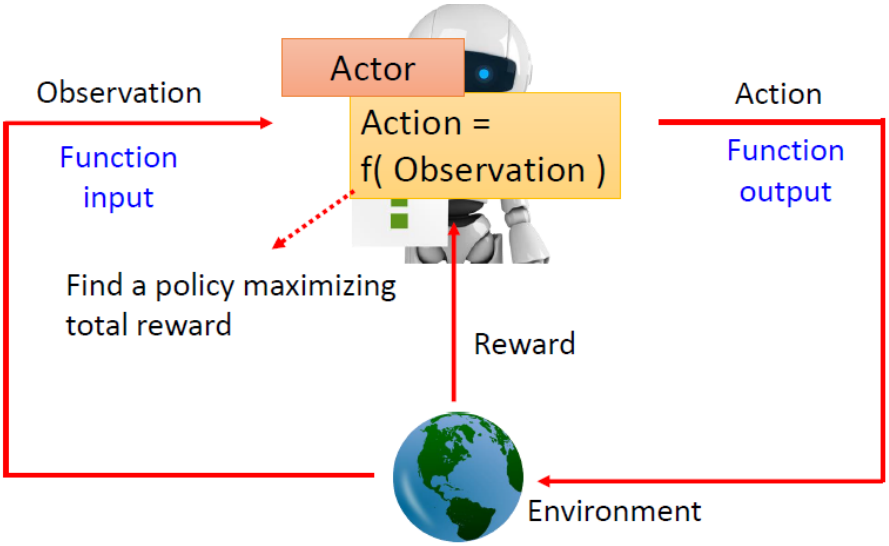

actor 以 environment 提供的 **observation 作為輸入**，而 actor 收到 observation 後，會**輸出 action** 影響 environment，environment 受到 action 的影響**產生新的 observation**，**environment 會不斷地給 actor 一些 reward**，告訴他採取的 action 好不好

Example 1：Space Invader

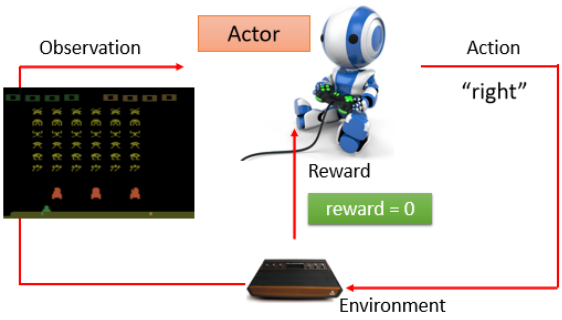

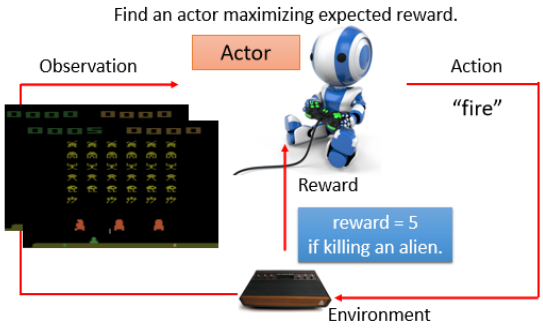

- actor：搖桿操控者
- environment：遊戲主機
- observation：遊戲畫面
- action：母艦向左、向右及開火
- reward：獲得的分數

要找一個 actor（function），可以使**得到的 reward 的總和最大**

Example 2：圍棋

- actor ：AlphaGo
- environment：人類對手
- observation：棋盤
- action：在 19×19 的棋盤上的落子
- reward：整局結束以後，贏得 1 分，輸得 0 分。**過程中不會得到 reward**

要找一個 actor（function），可以**使得到的 reward 的總和最大**

1.2 訓練三步驟

Step 1：Function with Unknown

actor 就是一個 network，稱為 **Policy Network**

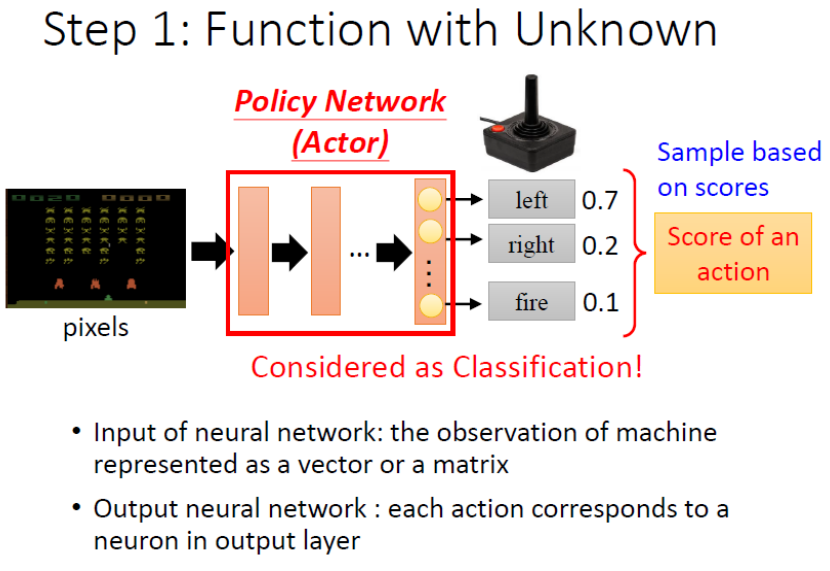

- 架構：FC、CNN、Transformer、……
- 輸入：遊戲的畫面 pixels
- 輸出：每個可採取行為的分數（向左 0.7 分、向右 0.2 分、開火 0.1 分，相加為 1）

把**輸出的分數當做機率，依照這些機率 sample** 出一個 action

Step 2：Define “Loss”

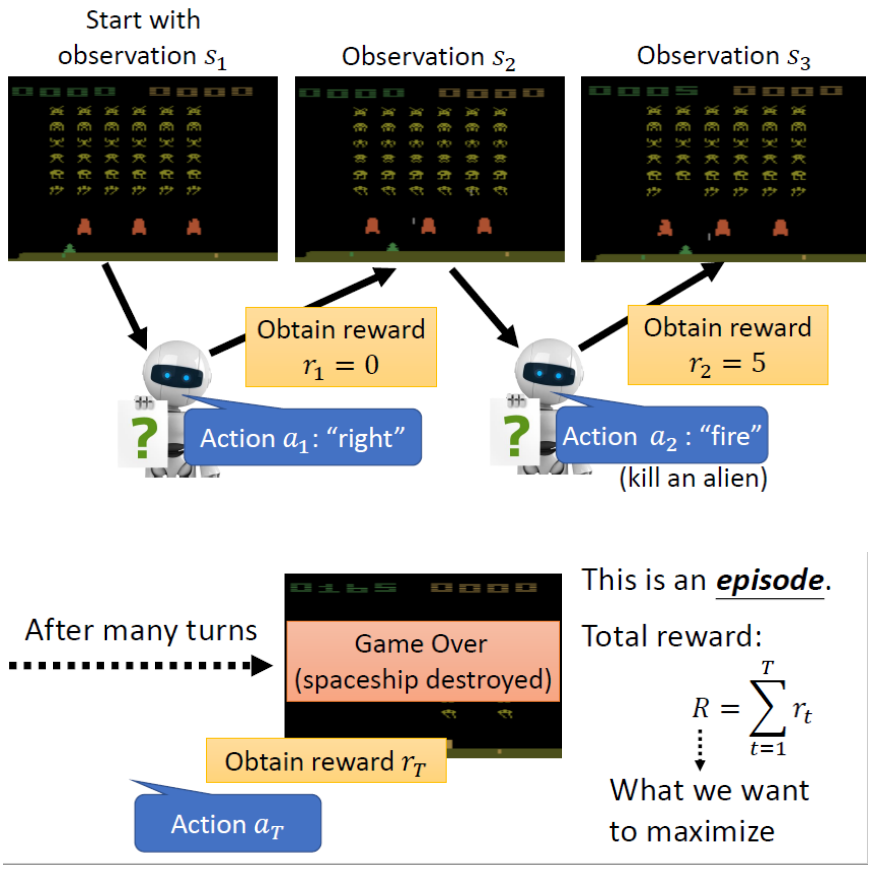

一整局遊戲稱為一個 **episode**，遊戲中每個行為都可能得到 reward，把**所有的 reward 相加得到整場遊戲的 total reward**，又稱為 **return**

- **Reward**：每個行為得到的反饋
- **Return**：整場遊戲得到的 reward 之和，目標是最大化 return，所以 **loss 即為** $-R$

Step 3：Optimization

對環境的 observation s_1，會變成 actor 的輸入，actor 依此輸出 action a_1，a_1 又作為環境的輸入，根據 a_1 輸出 s_2，以此類推，直至滿足遊戲終止條件

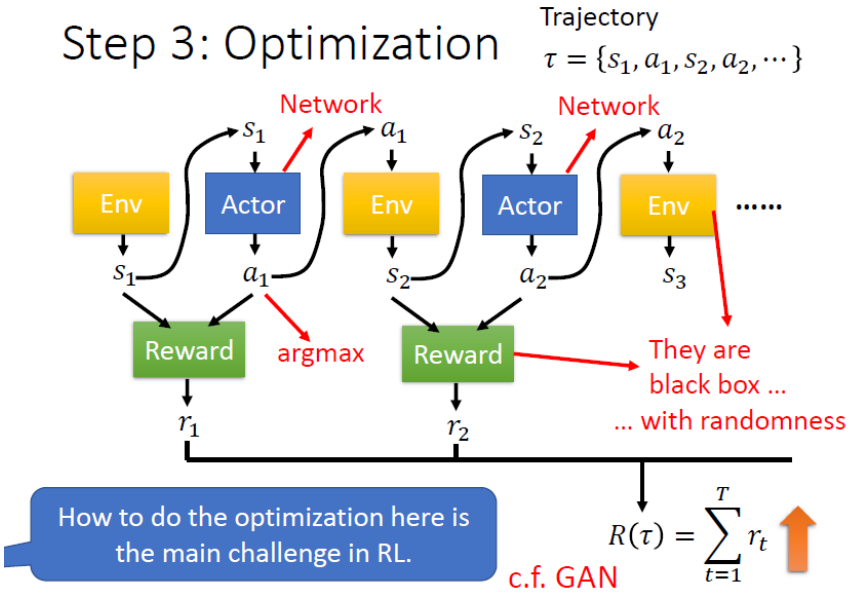

s 跟 a 所形成的 sequence $\{s_1, a_1, s_2, a_2, ...\}$ **稱作 Trajectory，以 τ 表示**

定義 **reward function 會考慮 action 和 observation 兩者**，把所有的 r 相加得到 R，即是要去最大化的對象

目標：

找到 actor 的一組參數，使得 $R(\tau)$ 越大越好

問題：

1. **actor 具有隨機性：**由於 action 是 sample 產生的，給定相同的 s，產生的 a 可能不一樣
2. **environment 和 reward 是黑盒子：**environment 和 reward 都不是 network，也都**具有隨機性**

總之，還是可以把 RL 看成三個階段，只是在 optimization 時，如何最小化 loss（最大化 return）跟之前學到的方法是不太一樣的

與 GAN 的異同之處

	GAN	RL
相同	訓練 generator 時，會把 generator 跟 discriminator 接在一起，調整 generator 的參數讓 discriminator 的輸出越大越好	RL 中，**actor 如同 generator**，**environment 跟 reward 如同 discriminator**，調整 actor 的參數，讓 environment 跟 reward 的輸出越大越好

	GAN	RL
相異	GAN 的 discriminator 是一個 neural network	**reward 跟 environment 不是 network**，是一個黑盒子，無法用一般 gradient descent 調整參數，來得到最大的輸出

2. Optimization：Policy Gradient

更詳細介紹 Policy Gradient：https://youtu.be/W8XF3ME8G2I

2.1 如何控制 Actor

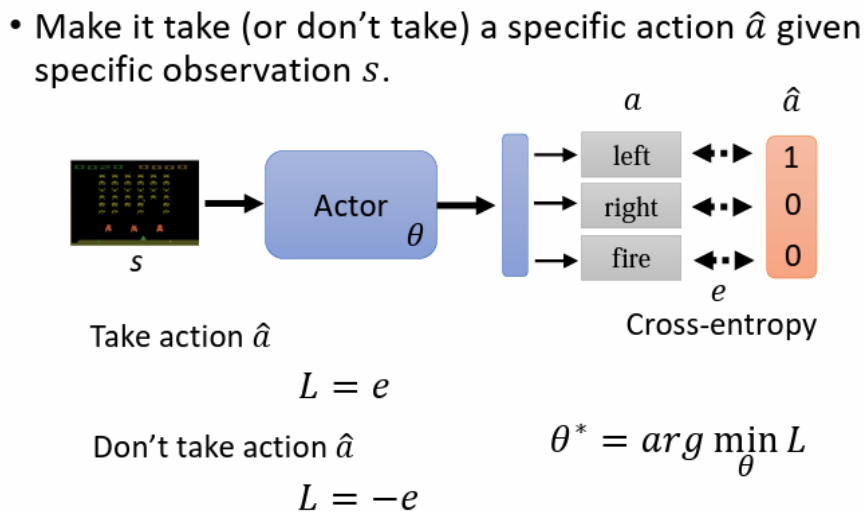

- 若希望 actor 在看到某個 s 時**採取某一 action**，只需將其**看做一般的分類問題**即可，為其設定 ground truth $\hat{a}$，**loss e 採用 cross-entropy**
- 若希望 actor 在看到某個 s 時**不採取某一 action**，只需**將 cross-entropy 乘一個負號**，最小化 L 等同於最大化 e，以使 actor 的 action 離 $\hat{a}$ 更遠

綜合以上兩種情況，可將 L **定義為** $e_1 - e_2$**，找到一組參數最小化** e_1**，同時最大化** e_2**，即可最小化 loss** L

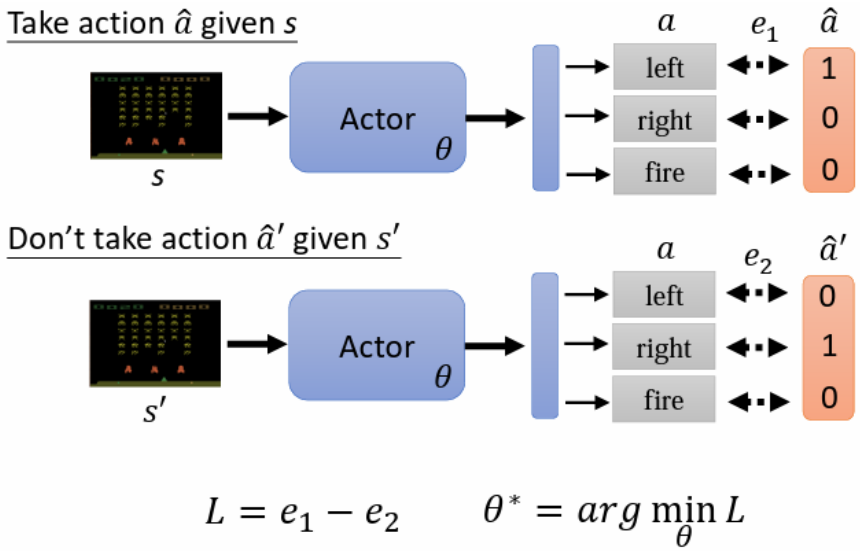

$$L = e_1 - e_2 \qquad \theta^* = arg\min_{\theta} L$$

2.2 收集訓練資料

方法：

1. 為每個行為標註為"好"或"不好"（+1、-1）

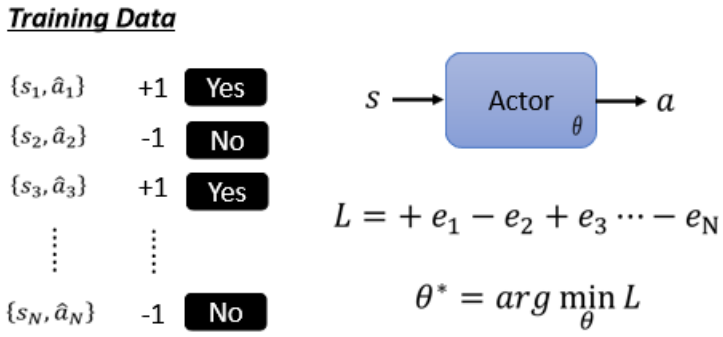

收集一堆某一 observation 下應該採取或不採取某一 action 的資料
定義 loss $L = +e_1 - e_2 + e_3 - \ldots - e_N$

2. 每個行為給定一個分數 A_n

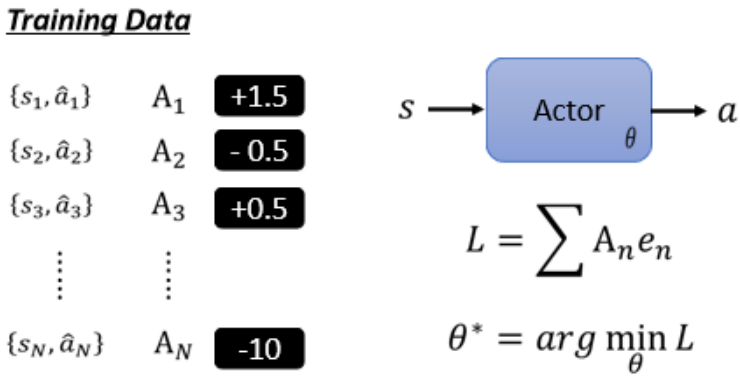

係數不再是只有正負 1
定義 loss $L = \sum A_n e_n$

問題：

- **<u>如何定義</u>** A_i（by Version 0 ~ Version 4）
- **如何產生 s 與 a 的 pair**

2.3 如何定義 A

Version 0 （不正確）

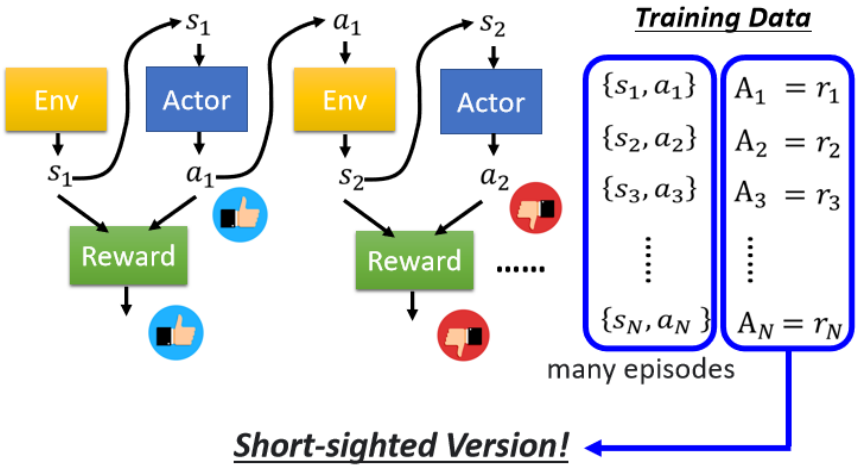

1. 首先定義一個隨機的 actor，**記錄若干個 episodes** 中 actor 與環境互動時，面對每一個 observation s 產生的 **action a**
2. 對記錄下來的每個 action 計算 reward
3. 將 reward 作為 A 用於定義 loss

問題：

短視近利，沒有長程規劃的概念
使用 Version 0，只要採取向左跟向右，得到的 reward 會是 0；只有開火時得到的 reward 是正的，導致機器會學到只有瘋狂開火才是對的，會一直傾向於射擊

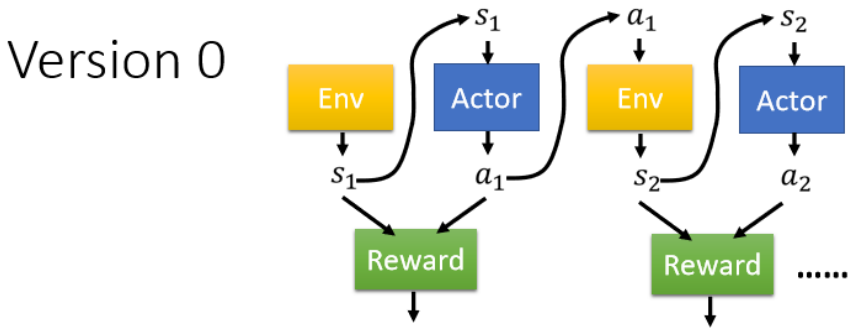

- An action affects the subsequent observations and thus subsequent rewards.
- *Reward delay*: Actor has to sacrifice immediate reward to gain more long-term reward.
- In space invader, only "fire" yields positive reward, so vision 0 will learn an actor that always "fire".

- 每一個行為並不是獨立的，每一個行為都會**影響到接下來發生**的事情
- **Reward Delay：需要犧牲短期的利益，以換取更長程的目標**

Version 1（Cumulated Reward）

Version 1 中，a_t 有多好，**不僅取決於 r_t，也取決於 a_t 之後所有的 reward**，也就是把 a_t 當下及之後的所有 action 得到的 reward 通通加起來，得到 G_t（**cumulated reward**）

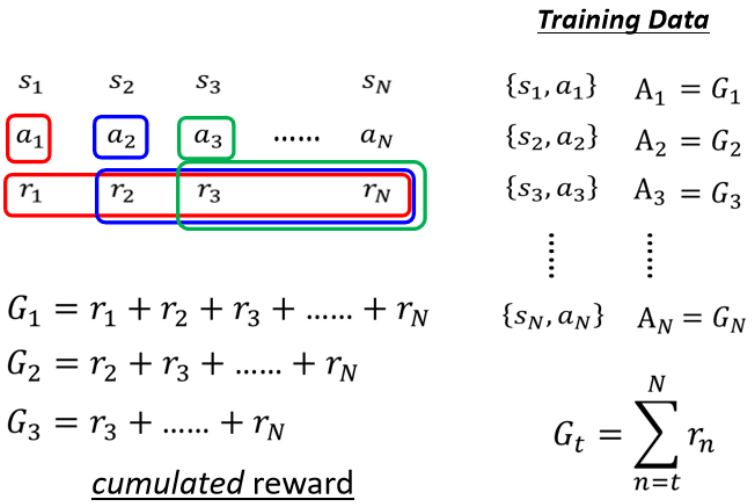

問題：

假設遊戲非常長，把 r_N 歸功於 a_1 也不合適

Version 2（Discounted Cumulated Reward）

改良 Version 1 的問題，**新增 discount factor** γ（$\gamma < 1$），離 a_t 比較近的 reward 給予較大的權重，較遠的 reward 給予較小的權重，使較遠的 reward 影響較小

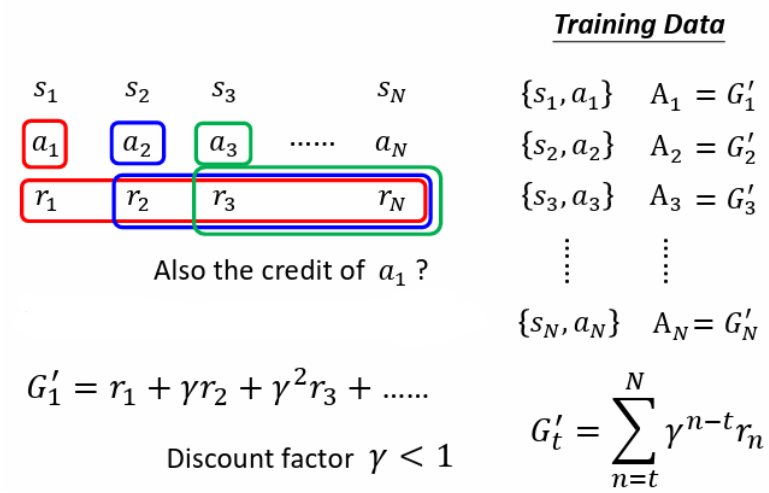

Version 3（標準化：-b）

假設某一遊戲得到的 reward 永遠都是正的，只是有大有小不同，因此每個 G 都會是正的，就算某些行為是不好的，還是會鼓勵機器採取某些行為，所以**需要做標準化，改良 Version 2，把所有 G' 減一個 baseline b**

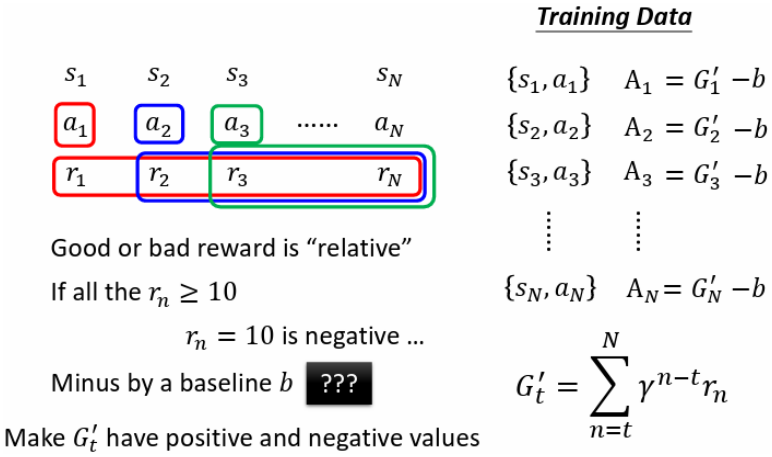

Version 3.5（b = value funtion）

訓練一個 critic，給一個 observation s，輸出 $V^\theta(s)$，讓 Version 3 的 $b = V^\theta(s)$

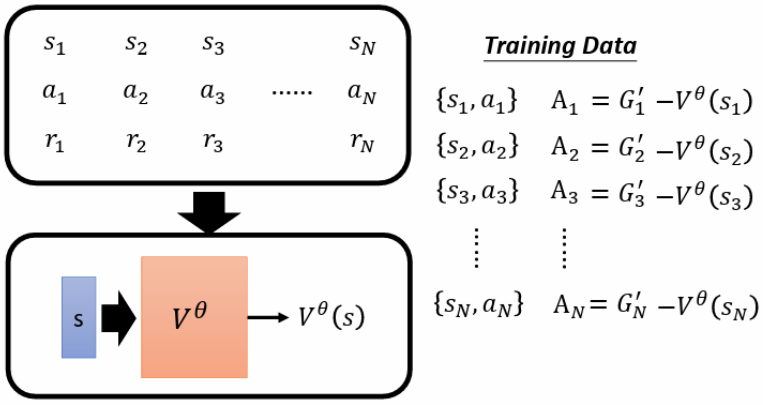

解釋：

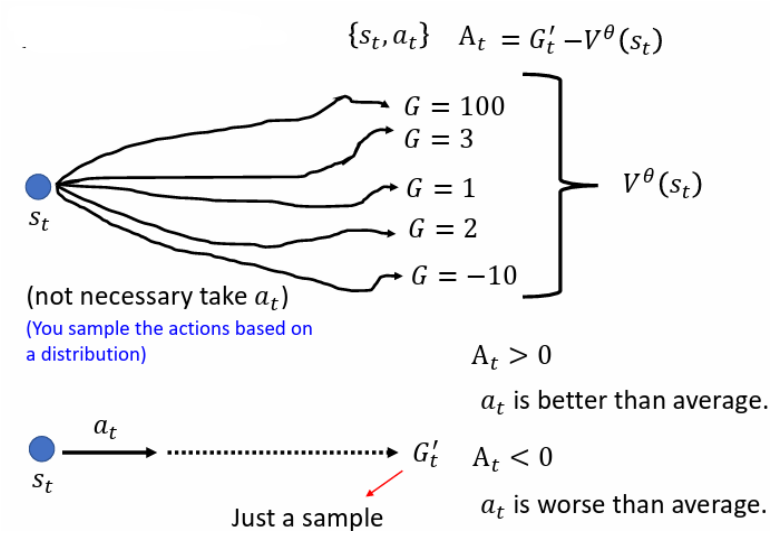

$V^\theta(s_t)$ 可以視為在 observation s_t 下，actor 採取各種可能的 action 後得到的 G'_t **期望值**

G'_t 則是真正結束一個 episode 後，得到的 discounted cumulated reward

A_t 是對 actor 在 observation s_t 下，採取 action a_t 的評價：

- 若 $A_t > 0$，表示 $G'_t > V^\theta(s_t)$，意義為採取特定 action a_t 得到的 G'_t 比隨機選擇一個 action 的期望值 $V^\theta(s_t)$ **好**，所以給予**正的評價** A_t
- 若 $A_t < 0$，表示 $G'_t < V^\theta(s_t)$，意義為採取特定 action a_t 得到的 G'_t 比隨機選擇一個 action 的期望值 $V^\theta(s_t)$ **不好**，所以給予**負的評價** A_t

問題：

$A_t = G'_t - V^\theta(s_t)$ 表示用一次 sample 的結果減去所有的“平均”，似乎不夠準確

解決：

Version 4（Advantage Actor-Critic）

Version 4（Advantage Actor-Critic）

在 observation s_t 下，採取 action a_t 到 s_{t+1}，考慮在 s_{t+1} 下採取各種 action a_{t+1} 的情況，並求所有 G'_{t+1} 的平均值（期望值）

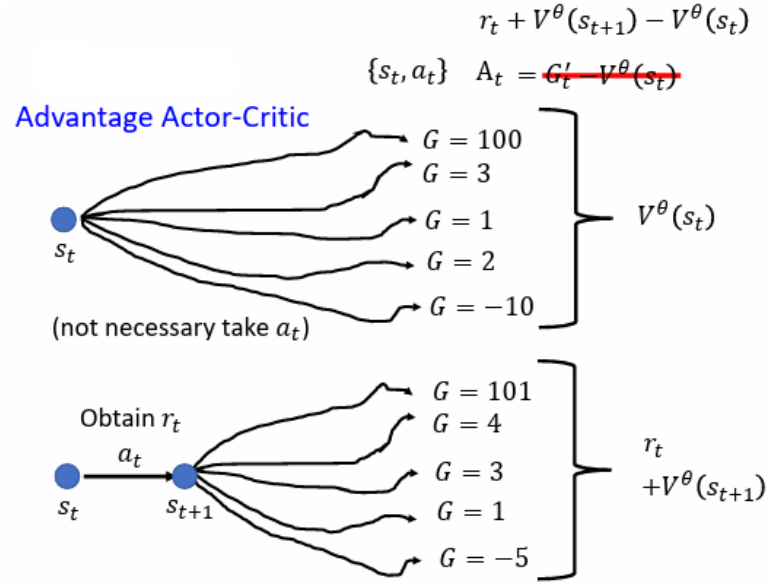

因為 **value function 意義上可以代表各種 action 的平均 discounted cumulated reward**，因此直接使用 $V^\theta(s_{t+1})$ 表示 s_{t+1} 下各種 a_{t+1} 得到的 G'_{t+1} 的平均值（期望值），所以將 G'_t 替換為 $r_t + V^\theta(s_{t+1})$

$\Rightarrow A_t = r_t + V^\theta(s_{t+1}) - V^\theta(s_t)$

2.4 訓練過程

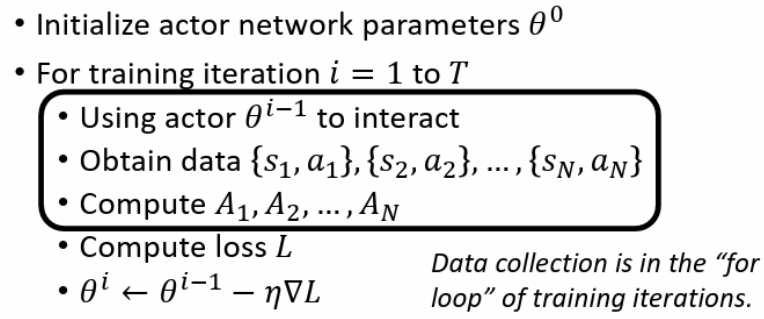

1. 隨機初始化 actor，參數為 θ^0
2. 迭代更新 actor

   用參數為 θ^{i-1} 的 actor 蒐集資料，並以此資料計算 A，再計算 loss L，做 gradient descent 更新參數

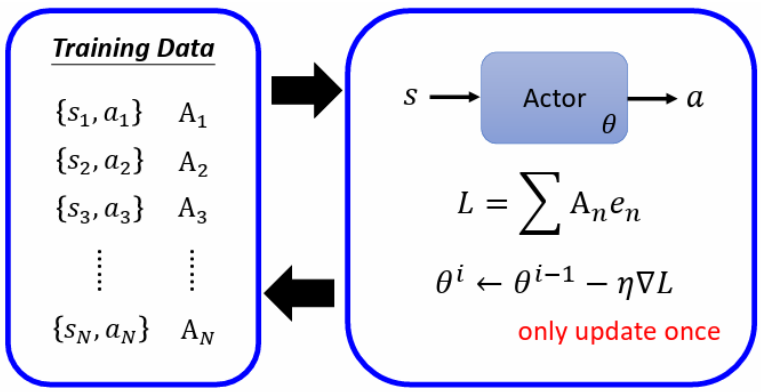

Each time you update the model parameters, you need to collect the whole training set again.

每次**更新完一次參數以後，資料就要重新再收集一次**，此舉非常花時間。而這麼做的目的是因為帶 θ^{i-1} 參數的 actor 收集到的資料，不一定適合拿來做為更新 θ^i 的資料帶 θ^i 參數的 actor 與帶 θ^{i-1} 參數的 actor 採取的 action 不會一樣，因而參考過去的 trajectory 沒有意義

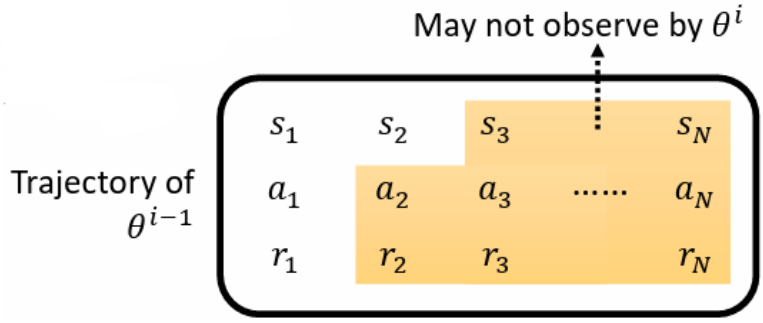

2.4.1 On-policy vs Off-policy

- The actor to train and the actor for interacting is the same. → On-policy
- Can the actor to train and the actor for interacting be different? → Off-policy

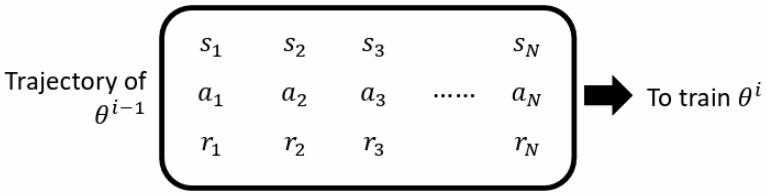

In this way, we do not have to collection data after each update.

- **On-policy Learning**：訓練的 actor 跟與環境互動的 actor 是**同一個**

- **Off-policy Learning**：訓練的 actor 跟與環境互動的 actor 是**不同的**
  好處是不用一直收集資料，可以用一次收集到的資料，更新多次 actor
  Proximal Policy Optimization（PPO）即是採用 off-policy learning，細節可參考：https://youtu.be/OAKAZhFmYoI

2.4.2 Exploration（增加 actor 做 action 的隨機性）

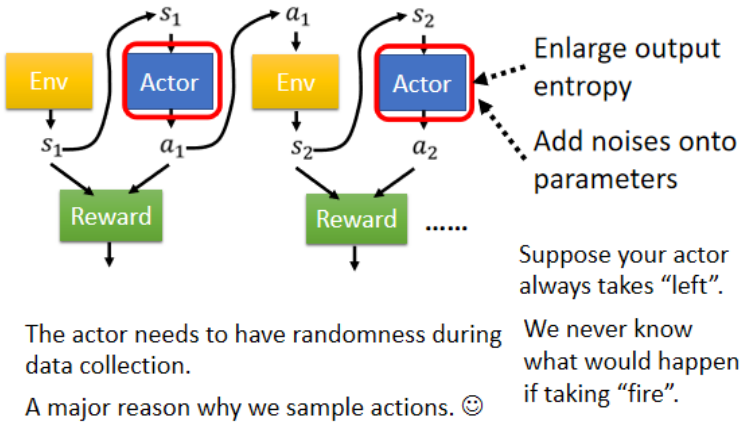

問題：

actor 所採取的 action 是 sample 而來的，因此 **actor 採取的 action 具有隨機性**
若一個 actor 採取行為的隨機性不夠，則一個 episode 結束後，所蒐集到的**資料中有些 actions 根本沒有被 sample 到，會導致無從知道這些 actions 的好壞**

解決：

期望跟環境互動的 actor 採取 actions 的隨機性要夠大，如此才能收集到比較豐富的資料
因此在訓練時，可藉由以下方式解決：

1. 刻意加大 actor 輸出的 distribution 的 entropy（比較容易 sample 到機率較低的 action）
2. 在 actor 參數上加 noise
3. …

Exploration 是 RL 訓練過程中重要的技巧

3. Critic

3.1 Value Function

有一 actor 參數為 θ，當前的 observation 為 s，value function $V^{\theta}(s)$ **為基於參數為 θ 的 actor 及 observation s，所預期的 discounted cumulated reward（期望值的概念）**

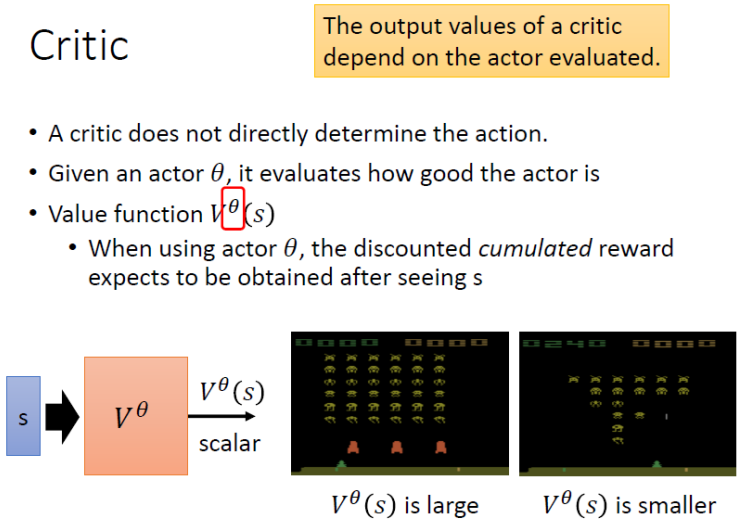

critic 做的事就是在**只看到當前 s 而尚未完成這局遊戲前**，就得到對參數為 θ 的 actor 的評價 $V^{\theta}(s)$

3.2 How to train critic

兩種方法訓練 critic：Monte Carlo 及 Temporal-Difference

3.2.1 Monte Carlo（MC） Based Approach

將 actor 拿去跟環境互動很多輪（episodes），得到一些遊戲的記錄（訓練資料）

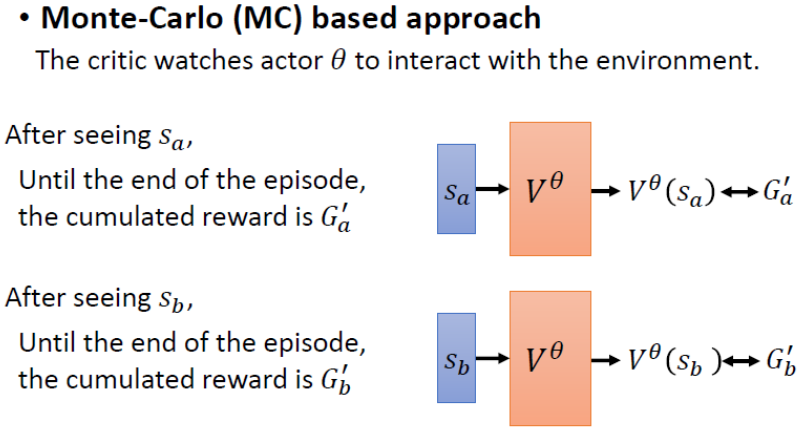

針對某一筆訓練資料，其 observation 為 s_a，$V^\theta(s_a)$ 要與 discounted cumulated reward G'_a 越接近越好。利用這些訓練資料，訓練 critic 以輸出期待的 $V^\theta(s)$

3.2.2 Temporal-Difference（TD） Approach

不需玩完整場遊戲（一個 episode）得到訓練資料。只要在看到 observation s_t，actor 執行 action a_t，得到 reward r_t，接下來再看到 observation s_{t+1}，就能夠更新一次 critic 參數。**此方法對於很長的遊戲或玩不完的遊戲非常合適**

觀察：

$V^\theta(s_t)$ 和 $V^\theta(s_{t+1})$ 之間有著代數關係：$V^\theta(s_t) = \gamma V^\theta(s_{t+1}) + r_t$
移項後可得：$V^\theta(s_t) - \gamma V^\theta(s_{t+1}) = r_t$

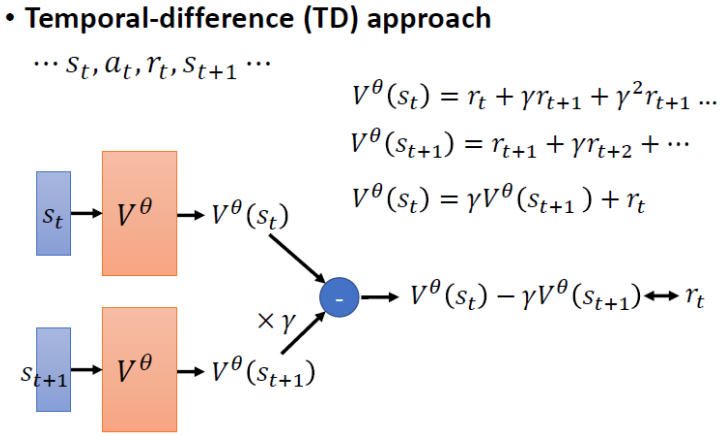

擁有 s_t, a_t, r_t, s_{t+1} 訓練資料，即可計算 $V^\theta(s_t) - \gamma V^\theta(s_{t+1})$，目標希望與 r_t 越接近越好

3.2.3 MC vs TD

由於 MC 與 TD 的背後的假設不同，訓練得到的 critic 也不同

- The critic has observed the following 8 episodes
  - $s_a, r = 0, s_b, r = 0$, END
  - $s_b, r = 1$, END
  - $s_b, r = 1$, END
  - $s_b, r = 1$, END
  - $s_b, r = 1$, END
  - $s_b, r = 1$, END
  - $s_b, r = 1$, END
  - $s_b, r = 0$, END

(Assume γ = 1, and the actions are ignored here.)

$V^\theta(s_b) = 3/4$

$V^\theta(s_a) =$? 0? 3/4?

Monte-Carlo: $V^\theta(s_a) = 0$

Temporal-difference:

$V^\theta(s_a) = V^\theta(s_b) + r$

3/4 3/4 0

MC 與 TD 得到的 $V^\theta(s_b)$ 都為 3/4，但 MC 得到的 $V^\theta(s_a)$ 為 0，而 TD 得到的 $V^\theta(s_a)$ 為 3/4

使用 critic 於訓練 actor 上：Version 3.5、Version 4

4. Tip of Actor-Critic

actor 與 critic 都是一個 network，兩者皆以 observation s 作為輸入，actor 輸出每一個 action 的機率分布；critic 輸出一個數值 $V^\theta(s)$

- The parameters of actor and critic can be shared.

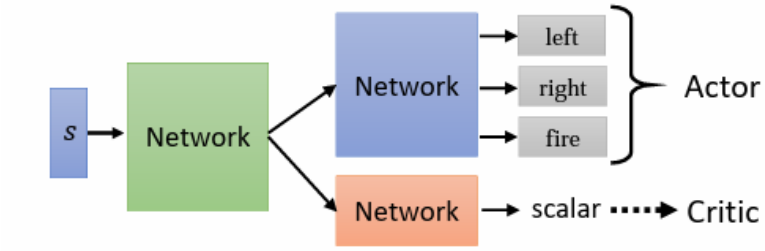

可將 actor 及 critic 兩個 network，**共用部分的 network**

5. To Learn More：DQN

直接使用 critic 決定要採取什麼 action，最知名的做法就是 Deep Q Network（DQN），細節可參考：https://youtu.be/o_g9JUMw1Oc、

https://youtu.be/2zGCx4iv_k

DQN 的變形：*Rainbow: Combining Improvements in Deep Reinforcement Learning*（**Rainbow**）

6. Reward Shaping

6.1 Sparse Reward

問題：

Sparse Reward 就是 **reward 大多數情況都是 0**，只有在少數情況是一個非常大的數值。意味著很多 actions 無從判斷是好是壞。例如圍棋到遊戲結束才會有 reward，過程中都沒有 reward

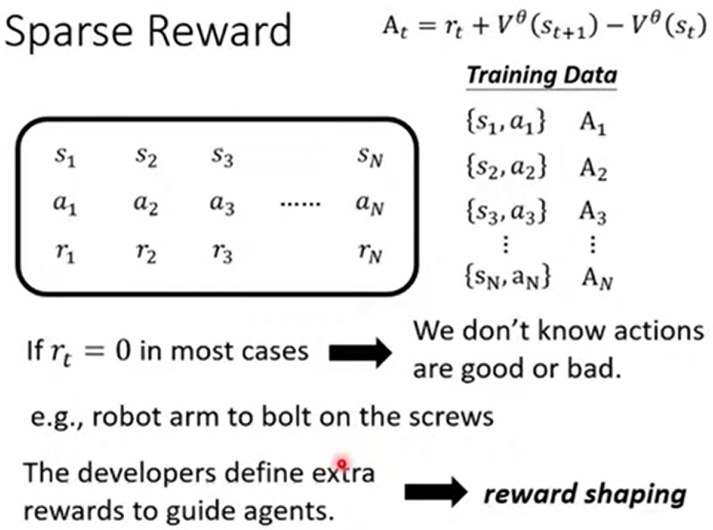

解決：

Reward Shaping：定義一些**額外的 reward** 來幫助 actor 學習

舉例：

如射擊類遊戲，除贏得勝利得到 +reward 及輸掉遊戲得到 - reward 外，額外定義了其他行為可以得到正的或負的 reward，如撿到補血包（+）、待在原地（+）、存活（-）等等

VizDoom https://openreview.net/forum?id=Hk3mPK5gg&noteId=Hk3mPK5gg

Parameters	Description	FlatMap | CIGTrack1
living	Penalize agent who just lives	-0.008 / action
health_loss	Penalize health decrement	-0.05 / unit
ammo_loss	Penalize ammunition decrement	-0.04 / unit
health_pickup	Reward for medkit pickup	0.04 / unit
ammo_pickup	Reward for ammunition pickup	0.15 / unit
dist_penalty	Penalize the agent when it stays	-0.03 / action
dist_reward	Reward the agent when it moves	9e-5 / unit distance

因此 reward shaping 都要倚靠人類的 domain knowledge 來定義

6.2 Curiosity

reward shaping 的其中一種做法：**Curiosity based reward shaping**

Reward Shaping - Curiosity https://arxiv.org/abs/1705.05363

Obtaining extra reward when the agent sees something new (but meaningful).

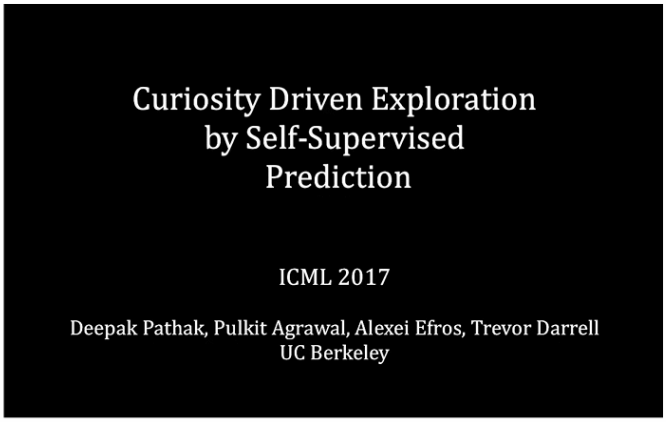

基於好奇心，讓 actor 看到有意義的新東西時獲得 reward

7. No Reward：Imitation Learning

問題：

- 遊戲中雖然容易定義 reward，但在其他任務要定義 reward 很困難
- 人工設置一些 reward（reward shaping）教機器學時，若 reward 沒設定好，機器可能會產生奇怪、無法預期的行為

解決：

沒有 reward 的狀況下，可使用 imitation learning

7.1 Imitation Learning

在沒有 reward 的情況下訓練 actor

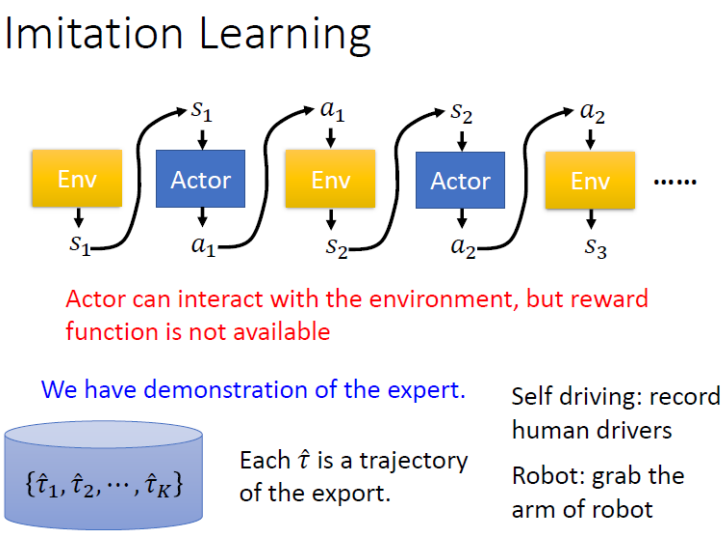

引入 expert（通常為人類）的示範。找很多 experts 跟環境互動，記錄互動的結果 $\hat{\tau}$，每個 $\hat{\tau}$ 代表一個 trajectory

舉例：

- 自動駕駛：記錄人類的駕駛行為
- 機械手臂：拉著機器的手臂示範

7.1.1 Behavior Cloning

類似於**監督式學習**，讓機器做出的 action 跟 export 做出的 action 越接近越好，又稱作 **Behavior Cloning**

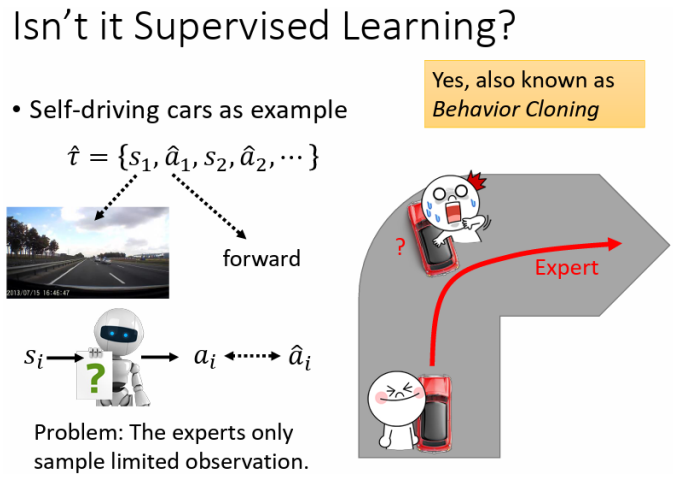

問題：

- experts 的記錄有限，若 actor 遇到從沒見過的情境，可能會做出無法預期的 action
- experts 做出的一些 actions actor 並不一定需要學習模仿，模仿的行為可能不會帶來好的結果

7.1.2 Inverse Reinforcement Learning

從 expert 的 demonstration，還有 environment 去反推 reward funtion，學出一個 reward funtion 後，再用一般的 RL 來訓練 actor

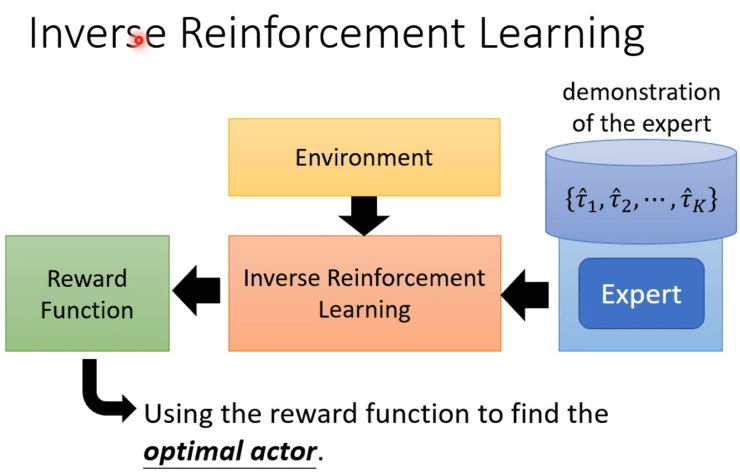

如何找出 reward funtion？

原則：teacher 的行為總是最好的

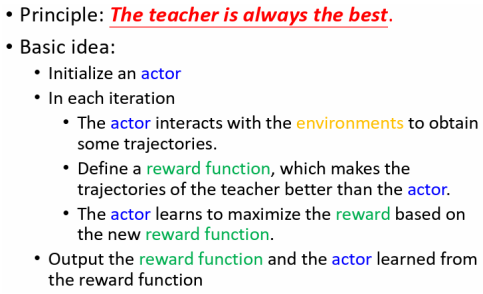

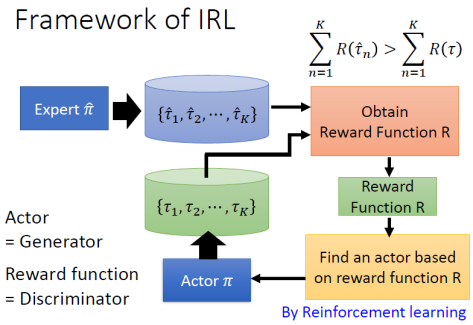

步驟：

1. 初始化一個 actor
2. 迭代訓練
    1. actor 與環境互動獲得多個 trajectory τ

2. 定義（更新）一個 reward function，能夠使老師的 reward 總和 $\Sigma R(\hat{\tau})$ 比 actor 的 reward 總和 $\Sigma R(\tau)$ 更高
3. 利用定義的 reward function 進行訓練，更新 actor 的參數，使 actor 能夠最大化 reward

3. 輸出 reward function 以及訓練得到的 actor

GAN vs IRL

IRL 就如同 GAN，actor 可視為 generator；reward function 可視為 discriminator